Koncepcja Modułu Weryfikacji Decyzji AI

1. Problem

Sztuczna sieć CNN jest stosowana między innymi do rozpoznawania obrazów. W typowym modelu klasyfikacyjnym funkcja Softmax przekształca wyniki modelu w wartości tworzące rozkład prawdopodobieństwa dla poszczególnych klas. Wartości te mogą jednak nie odzwierciedlać rzeczywistej wiarygodności predykcji.

Jednym z problemów jest słaba kalibracja pewności predykcji. Oznacza to, że wartości prawdopodobieństwa przypisywane przez model nie zawsze odpowiadają rzeczywistej częstości poprawnych przewidywań. W praktyce model może przypisać wysokie prawdopodobieństwo również błędnej klasyfikacji. [1]

Kolejnym problemem jest brak mechanizmu wykrywania obiektów spoza klas znanych podczas treningu. Standardowy klasyfikator może przypisać taki obiekt do jednej z dostępnych klas, nawet jeśli żadna z nich nie jest właściwa. Dlatego warto rozważyć dodatkowy mechanizm wykrywania takich przypadków i oznaczania ich jako potencjalnie niepewne. [2]

2. Metody oceny wiarygodności predykcji

Jedną z podstawowych metod oceny wyniku klasyfikatora jest analiza pewności predykcji (confidence score). W przypadku modelu wykorzystującego funkcję Softmax można przyjąć najwyższą wartość wyjściową jako miarę pewności przypisania obrazu do wybranej klasy. Wartość ta wskazuje, która klasa uzyskała najwyższy wynik wśród rozważanych kategorii. Przykładowo, jeżeli klasyfikator przypisze znakowi drogowemu wyniki 0,92, 0,05 i 0,03 dla trzech rozważanych klas, najwyższy wynik wyniesie 0,92. Może on zostać wykorzystany przez moduł weryfikacji jako wskaźnik pewności predykcji. Należy jednak pamiętać, że wysoki wynik Softmax nie gwarantuje poprawności rozpoznania. Współczesne sieci neuronowe mogą być słabo skalibrowane, co oznacza, że wartości przypisywane przez model nie zawsze odpowiadają rzeczywistej częstości poprawnych przewidywań [1]. Dlatego sam wynik pewności nie wystarcza do potwierdzenia poprawności klasyfikacji i powinien być oceniany na podstawie testów.

Kolejną metodą oceny wiarygodności predykcji jest analiza marginesu (margin). Polega ona na obliczeniu różnicy między dwoma najwyższymi wynikami prawdopodobieństwa zwróconymi przez klasyfikator. Wartość marginesu informuje, jak bardzo najwyżej oceniona klasa wyróżnia się na tle drugiej w kolejności klasy. Margines można obliczyć według wzoru:

$$M(x) = p_{(1)(x)} - p_{(2)(x)}$$

gdzie $\left(\mathrm{p}_{\{(1)\}(\mathrm{x})}\right)$oznacza najwyższy wynik, a $\left(\mathrm{p}_{\{(2)\}(\mathrm{x})}\right)$ drugi najwyższy wynik klasyfikatora dla obrazu (x).

Przykładowo, jeżeli dwa najwyższe wyniki wynoszą odpowiednio 0,92 i 0,05, margines wynosi 0,87. Jeżeli natomiast wyniki wynoszą 0,52 i 0,45, margines wynosi 0,07. Mniejszy margines oznacza, że dwie najlepiej ocenione klasy uzyskały zbliżone wyniki, co może wskazywać na większą niepewność klasyfikacji. Margines nie gwarantuje jednak poprawności predykcji. Model może uzyskać dużą różnicę między dwoma najwyższymi wynikami, a mimo to wskazać błędną klasę. Ponadto metoda ta uwzględnia jedynie dwa najwyższe wyniki, nie analizując całego rozkładu prawdopodobieństwa [4].

Entropia predykcji jest miarą wykorzystywaną do oceny niepewności klasyfikatora. W przeciwieństwie do confidence i marginesu uwzględnia wyniki dla wszystkich klas, a nie tylko najwyższy wynik lub różnicę między dwoma najwyższymi wynikami. Entropię można obliczyć według wzoru:

$$H(x) = -\sum_{i=1}^{K} p_i\,(x) \log p_i\,(x)$$

gdzie $\left(\mathrm{H}(\mathrm{x})\right)$ oznacza entropię dla obrazu (x), (K) jest liczbą klas, a $\left(p_i(x)\right)$ oznacza wynik przypisany klasie (i).

Niska entropia oznacza, że wyniki klasyfikatora są skoncentrowane wokół jednej klasy. Wysoka entropia wskazuje natomiast na bardziej równomierny rozkład wyników, co może świadczyć o większej niepewności predykcji [5]. W projektowanym module weryfikacji entropia może stanowić dodatkową miarę pomagającą wykrywać przypadki, w których klasyfikator nie wskazuje wyraźnie jednej klasy. Nie gwarantuje ona jednak poprawności rozpoznania, dlatego jej przydatność należy ocenić na podstawie testów.

3. Koncepcja podejmowania decyzji przez moduł weryfikacji

Na podstawie wyników klasyfikatora moduł weryfikacji będzie oceniał, czy predykcja może zostać zaakceptowana, czy wymaga dodatkowego ostrzeżenia, czy też powinna zostać odrzucona jako niewystarczająco wiarygodna. Takie podejście jest związane z klasyfikacją selektywną (selective classification), w której system może powstrzymać się od zaakceptowania wybranych predykcji, zamiast udzielać odpowiedzi dla każdego przypadku [6].

W projekcie proponuje się trzy możliwe decyzje modułu:

- Akceptacja predykcji — wynik spełnia przyjęte kryteria wiarygodności.
- Ostrzeżenie — wynik wskazuje na możliwą niepewność i powinien być traktowany ostrożnie.
- Odrzucenie predykcji — wynik nie spełnia minimalnych kryteriów wymaganych do jego zaakceptowania.

Decyzje mogą być podejmowane na podstawie wybranych miar, takich jak confidence, margin i entropy. Progi decyzyjne należy ustalić i ocenić na podstawie wyników uzyskanych na danych walidacyjnych i testowych, a nie przyjmować bez sprawdzenia. Należy podkreślić, że odrzucenie predykcji nie oznacza automatycznie, że klasyfikacja jest błędna. Oznacza jedynie, że moduł nie uznał jej za wystarczająco wiarygodną. Skuteczność zaproponowanych reguł zostanie oceniona w dalszej części projektu przez porównanie decyzji modułu z rzeczywistą poprawnością klasyfikacji.

Źrodła:
[1] - https://proceedings.mlr.press/v70/guo17a.html

[2] - https://arxiv.org/abs/2110.11334

[3] - https://link.springer.com/article/10.1007/s13748-025-00404-w

[4] - https://link.springer.com/article/10.1007/s10462-023-10562-9

[5] - https://papers.neurips.cc/paper_files/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html